

به نام خدا



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده برق و کامپیوتر



شناسائی الگو

تمرین شماره ۵

سجاد پاکدامن ساوجی

۸۱۰۱۹۵۵۱۷

فهرست

سوال ۱	۴
سوال ۲	۶
سوال ۳	۸
سوال ۴	۹
سوال ۵	۱۰

چکیده


در این تمرین با مباحث support vector machines بیشتر از پیش آشنا شدیم. در سوالات ابتدایی با نحوه‌ی ساخت کرنل (هسته‌های جدید) از روی هسته‌های موجود آشنا شدیم و در سوالات پایانی هم به پیاده‌سازی و استفاده از این طبقه‌بند با کرنل خطی و RBF پرداختیم.

در تمرین پایانی در ابتدا مشکل هسته‌هایی با درجه فضای بی‌نهایت مانند RBF را متوجه شدیم که به علت درجه آزادی بیش‌از حدی که دارند به سادگی روی داده‌ها overfit می‌شوند. در ادامه اهمیت پارامترهای مدل svm را دیدیم و متوجه شدیم که با یک grid search ساده می‌توان مدل را fine tune کرد و به دقت‌های بسیار بالاتری رسید.

در سوال پایانی اهمیت normalization را در داده‌ها مشاهده کردیم که با یک normalization ساده می‌توان به صورت قابل توجهی عملکرد طبقه‌بند را افزایش داد.

problem 1) $\text{conv}[X^+] = \sum_{i: y_i=1} \lambda_i x_i$ $\text{conv}[X^-] = \sum_{j: y_j=-1} \lambda_j x_j$

$$\min_{\lambda} \left\| \sum_i \lambda_i x_i - \sum_j \lambda_j x_j \right\|^2 \quad \text{s.t.:} \quad \sum_i \lambda_i = 1, \quad \sum_j \lambda_j = 1, \quad \lambda_i \geq 0$$



$$\left\| \sum_i \lambda_i x_i - \sum_j \lambda_j x_j \right\|^2 = \left(\sum_i \lambda_i x_i - \sum_j \lambda_j x_j \right)^T \left(\sum_i \lambda_i x_i - \sum_j \lambda_j x_j \right)$$

$$= \left(\sum_i \lambda_i x_i^T - \sum_j \lambda_j x_j^T \right) \left(\sum_i \lambda_i x_i - \sum_j \lambda_j x_j \right)$$

$$= \sum_i \sum_{i'} \lambda_i \lambda_{i'} \underbrace{x_i^T x_{i'}}_A + \sum_j \sum_{j'} \lambda_j \lambda_{j'} \underbrace{x_j^T x_{j'}}_B - 2 \sum_i \sum_j \lambda_i \lambda_j \underbrace{x_i^T x_j}_P$$

$$= \begin{bmatrix} \lambda_i \\ \lambda_j \end{bmatrix}^T \begin{bmatrix} A & -P \\ -P & B \end{bmatrix} \begin{bmatrix} \lambda_i \\ \lambda_j \end{bmatrix} = \mathcal{L}^T \mathcal{D} \mathcal{L}$$

$$\text{minimize } \mathcal{L}^T \mathcal{D} \mathcal{L} \quad \text{s.t.} \quad \mathcal{L}^T \mathbf{1} = 2, \quad \mathcal{L} \geq 0$$

$$\begin{aligned} & \sum_i \sum_{i'} \underbrace{y_i y_{i'}}_1 \lambda_i \lambda_{i'} x_i^T x_{i'} + \sum_j \sum_{j'} \underbrace{y_j y_{j'}}_1 \lambda_j \lambda_{j'} x_j^T x_{j'} + \sum_i \sum_j \underbrace{y_i y_j}_{-1} x_i^T x_j \\ & + \sum_j \sum_i \underbrace{y_i y_j}_{-1} x_i^T x_j = \sum_{i,j} y_i y_j x_i^T x_j \lambda_i \lambda_j \end{aligned}$$

$$\begin{aligned} \text{minimize } \sum_{i,j} y_i y_j x_i^T x_j \lambda_i \lambda_j \quad & \text{s.t.} \quad \sum_i \lambda_i = 1, \quad \sum_j \lambda_j = 1 \\ & \equiv \sum_{k=1}^N \lambda_k = 2, \quad \sum_{k=1}^N y_k \lambda_k = 0 \\ & , \mathcal{L} \geq 0 \end{aligned}$$

$$\text{optimize } \sum_{i,j} y_i y_j x_i^T x_j \lambda_i \lambda_j \quad \text{s.t. } \lambda > 0 \quad 1^T \lambda = 2 \quad -\lambda^T y = 0$$

$$\Rightarrow \text{optimize } 2 - \lambda^T D \lambda = \text{optimize } 1^T \lambda - \frac{1}{2} \lambda^T D \lambda$$

$$\text{s.t. } 1^T \lambda = 1, \quad -\lambda^T y = 0, \quad \lambda > 0$$

* which is dual problem of hard margin SVM

Problem 2)

$$A) k(u, v) = \alpha k_1(u, v) - \beta k_2(u, v) \quad , \alpha, \beta \geq 0$$

is invalid. consider the case $\alpha=1, \beta=1$, $k_2(u, v) = k_1(u, v) \Rightarrow k(u, v) = 0$

which is not PD.

$$B) K(u, v) = k_1(u, v) k_2(u, v)$$

$$k_1(u, v) = \langle \phi_1(u), \phi_1(v) \rangle = \phi_1^T(u) \phi_1(v)$$

$$k_2(u, v) = \langle \phi_2(u), \phi_2(v) \rangle = \phi_2^T(u) \phi_2(v)$$

$$k_1(u, v) k_2(u, v) = \phi_1^T(u) \phi_1(v) \times \phi_2^T(u) \phi_2(v)$$

$$\phi_1(u) = [a_1(u) \dots a_m(u)]^T \quad \phi_2(u) = [b_1(u) \dots b_n(u)]^T$$

$$\phi_1^T(u) \phi_1(v) = \sum_{i=1}^m a_i(u) a_i(v) \quad , \quad \phi_2^T(u) \phi_2(v) = \sum_{j=1}^n b_j(u) b_j(v)$$

$$\phi_1^T(u) \phi_1(v) \times \phi_2^T(u) \phi_2(v) = \sum_{j=1}^n \sum_{i=1}^m a_i(u) a_i(v) b_j(u) b_j(v)$$

$$= \sum_{j=1}^n \sum_{i=1}^m \underbrace{a_i(u) b_j(u)}_{c_{ij}(u)} \times \underbrace{a_i(v) b_j(v)}_{c_{ij}(v)} = \sum_{j=1}^n \sum_{i=1}^m c_{ij}(u) c_{ij}(v) \rightarrow \text{inner product}$$

$$c) k(u, v) = \exp \left\{ -\frac{\|u-v\|^2}{\sigma^2} \right\} = \exp \left\{ -\frac{1}{\sigma^2} [(u-v)^T (u-v)] \right\}$$

$$= \exp \left\{ -\frac{1}{\sigma^2} [(u^T u) + (v^T v) - 2 u^T v] \right\}$$

$$= \underbrace{\exp \left\{ -\frac{1}{\sigma^2} (u^T u + v^T v) \right\}}_{c_0} \exp \left\{ \frac{2}{\sigma^2} u^T v \right\}$$

teybr expansion

$$\rightarrow c_0 \sum_{i=1}^{\infty} \frac{1}{i!} (c_1 u^T v)^i$$

\hookrightarrow product of kernels and sum of kernels are kernel \checkmark

D) $k(u, v) = g(u)g(v)$ Mercer's theorem

$$\iint k(u, v) g(u) g(v) du dv = \iint g^2(u) g^2(v) du dv = \underbrace{\int g^2(u) du}_{\geq 0} \times \underbrace{\int g^2(v) dv}_{\geq 0}$$

if $g(u), g(v) \in L^2 \Rightarrow k(u, v)$ is Mercer kernel

E) $k(u, v) = f(k_i(u, v))$

$$f(x) = \sum_{i=1}^{\infty} a_i x^i \quad \text{Polynomial} \Rightarrow f(k_i(u, v)) = \sum_{i=1}^{\infty} a_i k_i(u, v)$$

product of kernels are kernel $\Rightarrow k_i(u, v) \rightarrow$ is kernel

sum of kernels with positive factors is kernel

$$\Rightarrow \sum_{i=1}^{\infty} a_i k_i(u, v) \rightarrow \text{is kernel}$$

problem 3)

1. relax conditions $y_i(w^T x_i + b) \geq 1 - \epsilon_i$, $\epsilon_i \geq 0$


minimize $\frac{1}{2} w^T w$ s.t: $y_i(w^T x_i + b) \geq 1 - \epsilon_i$, $\epsilon_i \geq 0$

2. $\epsilon_i = 0 \Rightarrow y_i(w^T x_i + b) \geq 1$
either on margin or correct classified

$\epsilon_i = 1 \Rightarrow y_i(w^T x_i + b) \geq 0$
either on the hyper plane or in the
corresponding margin

$0 < \epsilon_i < 1 \Rightarrow$ data point is in the margin

$\epsilon_i > 1 \Rightarrow$ miss classified



problem 4) $J(\underline{w}, \underline{\varepsilon}) = \frac{1}{2} \underline{w}^T \underline{w} + \frac{1}{2} \sum_{i=1}^l \varepsilon_i^2$

$$L(\underline{w}, \underline{\varepsilon}, \underline{\lambda}, \underline{R}, b) = \frac{1}{2} \underline{w}^T \underline{w} + \frac{1}{2} \sum_{i=1}^l \varepsilon_i^2 - \sum_{i=1}^l \alpha_i [y_i (\underline{w}_i^T \underline{w} + b) - 1] - \sum_{i=1}^l \varepsilon_i (d_i + r_i)$$

$$\frac{\partial L}{\partial \underline{w}} = 0 \Rightarrow \underline{w} = \sum_{i=1}^l \alpha_i y_i \underline{x}_i \quad \frac{\partial L}{\partial b} = 0 \Rightarrow -\underline{\lambda}^T \underline{y} = 0$$

$$\frac{\partial L}{\partial \varepsilon_i} = 0 \Rightarrow \varepsilon_i = r_i + \alpha_i \Rightarrow \underline{\varepsilon} = \underline{R} + \underline{\lambda}$$

$$L(\underline{w}, \underline{\varepsilon}, \underline{\lambda}, \underline{R}) = \underline{\lambda}^T \underline{\lambda} - \frac{1}{2} \underline{\lambda}^T \underline{D} \underline{\lambda} + \frac{c}{2} \sum_{i=1}^l \varepsilon_i^2 - c \sum_{i=1}^l \varepsilon_i^2$$

$$L(\underline{\lambda}, \underline{\varepsilon}) = \underline{\lambda}^T \underline{\lambda} - \frac{1}{2} \underline{\lambda}^T \underline{D} \underline{\lambda} - \frac{c}{2} \sum_{i=1}^l \varepsilon_i^2$$

only ε_i^0 contributes to the sum $\sum_{i=1}^l \varepsilon_i^2$ and from KKT $\rightarrow \varepsilon_i r_i = 0$

\Rightarrow if $\varepsilon_i \neq 0 \rightarrow r_i = 0 \Rightarrow \varepsilon_i = d_i \Rightarrow$

$$L(\underline{\lambda}, \underline{\varepsilon}) = \underline{\lambda}^T \underline{\lambda} - \frac{1}{2} \underline{\lambda}^T \underline{D} \underline{\lambda} - \frac{c}{2} \underline{\lambda}^T \underline{\lambda}$$

$$L(\underline{\lambda}) = \underline{\lambda}^T \underline{\lambda} - \frac{1}{2} \underline{\lambda}^T \underbrace{[\underline{D} + c\underline{I}]}_{\underline{D}'} \underline{\lambda} \quad \text{s.t. } \underline{\lambda} \succeq 0, \underline{\lambda}^T \underline{y} = 0$$

$$L(\underline{\lambda}) = \underline{\lambda}^T \underline{\lambda} - \frac{1}{2} \underline{\lambda}^T \underline{D}' \underline{\lambda} \quad \text{s.t. } \underline{\lambda} \succeq 0, \underline{\lambda}^T \underline{y} = 0$$

\hookrightarrow just like hard margin optimization

thus it can be interpreted as linearly separable case.

دقت شود که پیاده سازی های خواسته شده در این سوال ، در jupyter notebook است که به همراه گزارش ارسال شده است.

۱. در قسمت اول برای جداسازی داده های آموزش از داده های آزمایش از تابع `train_test_split` استفاده کرد شد. سپس طبقه بند `svm` را بدون مشخص کردن پارامتر خاصی روی داده های آموزش داده شد. این طبقه بند بر روی داده های آموزش به دقت ۱۰۰ رسید در حالی که روی داده های آزمایش دقت آن ۴۲ بود. با توجه به نتایج بدست آمده این تحلیل ارائه می شود که به دلیل درجه آزادی بیش از حد طبقه بند روی داده های آموزش بیش برآزش یا همان `overfit` کرده است.

۲. در قسمت بعدی از یک طبقه بند `svm` با کرنل خطی استفاده شد. این طبقه بند روی داده های آموزش به دقت ۳۸ درصد و روی داده های آزمایش به دقت ۳۱ درصد رسید. با توجه به نتایج بدست آمده این تحلیل ارائه می شود که طبقه بند بیش برآزش انجام نداده است و علت خطای آن به دلیل ساختار با درجه آزادی کم با توجه با داده ها می باشد. یا به عبارتی این داده ها به صورت خطی جداپذیر نیستند.

۳. در این قسمت خواسته شده است که با استفاده از `normalization` طبقه بند ها را بهبود ببخشیم. در مورد طبقه بند `svm` با کرنل `RBF` ، روی داده های آموزش به دقت ۶۶ درصد و روی داده های آزمایش به دقت ۶۰ درصد رسید. مشاهده می شود که به علت عملیات `feature conditioning` دیگر مدل `overfit` نکرده است. برای `svm` با کرنل خطی نیز عملیات را انجام می دهیم و این طبقه بند روی داده های آموزش به دقت ۷۵ درصد و روی داده های آزمایش به دقت ۷۲ درصد رسید. مشاهده می شود که عملکرد `linear svm` نیز بهبود یافته است.

۴. در پایان بر روی داده های `normalized` شده با استفاده از `gridsearch` سعی کردیم که طبقه بند `svm` را با هسته `rbf` به پارامتر های بهینه برسانیم یا همان `fine tune` کنیم. مقادیر بهینه در زیر آمده اند

$$C = 287.5$$

$$\text{gamma} = 0.25$$

با این پارامتر ها طبقه بند به دقت ۹۴ درصد روی داده های آموزش رسید و روی داده های آزمایش به دقت ۷۷ رسید.

پیوست 1: روند اجرای برنامه

پیاده سازی های سوال ۵ در jupyter notebook به همراه گزارش ارسال شده است.

